

**ANALISIS SPASIAL-TEMPORAL POLA AKTIVITAS
PENDAKI GUNUNG BERBASIS SENSOR FUSION
MENGUNAKAN METODE HYBRID CNN-TRANSFORMER**

LAPORAN PROJECT

Disusun untuk memenuhi tugas Ujian Tengah Semester (UTS) Genap
mata kuliah Advanced Computer Vision



**Oleh:
AEP SUPRIADI
241210050070**

**PROGRAM STUDI TEKNIK INFORMATIKA S-2
PROGRAM PASCASARJANA
UNIVERSITAS PAMULANG
TANGERANG SELATAN
2026**

KATA PENGANTAR

Puji syukur penulis ucapkan kehadiran Allah SWT, karena atas berkat dan rahmat- Nya penulis dapat menyelesaikan laporan proyek ini. Penulisan laporan proyek ini dilakukan dalam rangka memenuhi tugas Ujian Kahir Semester (UTS) Genap pada Program Studi Magister Teknik Informatika UNPAM. Penulis menyadari bahwa tanpa bantuan dan bimbingan dari berbagai pihak, dari masa perkuliahan sampai menyusun laporan proyek ini, Oleh karena itu Penulis mengucapkan terimakasih kepada:

1. Bapak Dr. Pranoto, S.E., M.M selaku ketua Yayasan Sasmita Jaya.
2. Bapak Dr. E. Nurzaman, AM., M.M., M.Si selaku Rektor Universitas Pamulang.
3. Dr. Saiful Anwar, S.Pd., S.E., M.Pd. selaku Direktur Pascasarjana Universitas Pamulang.
4. Dr. Sajarwo Anggai, S.ST., M.T. sebagai Ketua Program Studi Magister Teknik Informatika S-2 Universitas Pamulang.
5. Dr. Arya Adhyaksa Waskita S.Si., M.Si sebagai Dosen Mata kuliah Advanced Computer Vision.

Akhir kata, penulis berharap Tuhan Yang Maha Esa berkenan membalas segala kebaikan semua pihak yang telah membantu. Semoga laporan proyek ini membawa manfaat bagi pengembangan ilmu pengetahuan.

Penulis,

Aep Supriadi

DAFTAR ISI

KATA PENGANTAR.....	1
DAFTAR ISI	2
DAFTAR TABEL.....	4
DAFTAR GAMBAR	5
BAB I PENDAHULUAN	6
1.1 Latar Belakang	6
1.2 Permasalahan Penelitian.....	8
1.2.1 Identifikasi Masalah	8
1.2.2 Ruang Lingkup Masalah	9
1.2.3 Rumusan Masalah	10
1.3 Tujuan dan Manfaat Penelitian	10
1.4 Sistematika Penulisan	10
BAB II LANDASAN TEORI DAN KERANGKA PEMIKIRAN	12
2.1 Tinjauan Pustaka	12
2.2 Landasaan Teori	18
2.2.1 <i>Human Activity Recognition</i> (HAR)	18
2.2.2 <i>Sensor Fusion</i>	19
2.2.3 Aplikasi Phyphox.....	19
2.2.4 <i>Deep Learning</i>	19
2.2.5 <i>Machine Learning</i>	20
2.2.6 <i>Convolutional Neural Network</i> (CNN)	20
2.2.7 (TRANSFORMER)	21
2.2.8 Arsitektur <i>Hybrid</i> CNN-TRANSFORMER.....	21
2.2.9 Python	22
2.2.10 Visual Studio Code.....	22
2.3 Kerangka Pemikiran.....	22
BAB III METODOLOGI	25
3.1 Analisis Kebutuhan	25
3.1.1 Kebutuhan Perangkat Keras	25
3.1.2 Kebutuhan Perangkat Lunak	25
3.2 Perancangan Penelitian	26
UNIVERSITAS PAMULANG	2

3.2.1	Pengumpulan Data (<i>Data Acquisition</i>)	26
3.2.2	Pra-pemrosesan Data (<i>Data Preprocessing</i>)	26
3.2.3	Arsitektur Model Hybrid CNN-TRANSFORMER	27
3.3	Teknik Analisis	27
BAB IV HASIL DAN PEMBAHASAN.....		29
4.1	Hasil Eksperimen	29
4.2	Analisis Proses Pelatihan	30
4.3	Evaluasi Performa Model	32
4.3.1	Confusion Matrix	32
4.3.2	Laporan Klasifikasi	33
BAB V PENUTUP.....		35
5.1	Kesimpulan.....	35
5.2	Saran	36
DAFTAR PUSTAKA		38

DAFTAR TABEL

Tabel 2 1 Penelitian Terdahulu.....	12
Tabel 3 1 Jadwal Penelitian.....	Error! Bookmark not defined.

DAFTAR GAMBAR

Gambar 2 1 Arsitektur CNN-TRANSFORMER	22
Gambar 2 2 Kerangka Pemikiran	24
Gambar 4 1 Ringkasan Arsitektur Model Hybrid CNN-TRANSFORMER.....	29
Gambar 4 2 Grafik perbandingan antara akurasi training dengan validasi dan loss training dengan validasi selama 15 epoch.....	31
Gambar 4 3 Confusion Matri	32
Gambar 4 4 Laporan Klasifikasi Metrik Evaluasi Per-Aktivitas	33

BAB I

PENDAHULUAN

1.1 Latar Belakang

Eskalasi tren pendakian gunung yang signifikan dalam beberapa tahun terakhir berbanding lurus dengan peningkatan risiko kecelakaan fatal akibat kelelahan fisik dan medan ekstrem yang sulit diprediksi. Upaya mitigasi bencana berbasis teknologi telah banyak dikembangkan, di mana riset-riset terkini mayoritas berfokus pada sistem pemantauan berbasis *Internet of Things* (IoT) untuk pelacakan lokasi dan tanda vital secara *real-time* (Sonawane et al., 2024). Namun, pendekatan IoT ini memiliki kelemahan fundamental ketika diterapkan di topografi pegunungan Indonesia yang didominasi area *blank spot*. Ketergantungan pada konektivitas jaringan baik seluler maupun LoRa Mesh seringkali menyebabkan kegagalan transmisi data kritis saat evakuasi darurat dibutuhkan (Penchalaiah et al., 2025).

Teknologi *Human Activity Recognition* (HAR) berbasis sensor *smartphone* hadir sebagai solusi yang paling menjanjikan karena efisiensi biaya dan ketersediaan perangkat yang luas (Yin et al., 2024). Dengan memanfaatkan *Inertial Measurement Unit* (IMU), kita dapat merekam jejak sinyal gerakan tubuh. Namun, tantangan utama yang dihadapi saat ini adalah penurunan performa model HAR ketika diterapkan di lingkungan liar (*in-the-wild*) dibandingkan dengan lingkungan laboratorium yang terkontrol, terutama akibat variabilitas posisi perangkat dan gerakan yang tidak terstruktur (Dutta et al., 2025).

Masalah mendasar yang disorot dalam penelitian ini adalah fenomena "Ambiguitas Sinyal" pada medan dengan elevasi ekstrem. Literatur terbaru tahun 2024 menunjukkan bahwa pola langkah (*gait*) pada aktivitas menanjak (*uphill*) memiliki karakteristik spasiotemporal yang sangat berbeda dengan berjalan datar, namun seringkali sulit dibedakan oleh algoritma standar (Contreras et al., 2024). Akibatnya, model rentan salah mengklasifikasikan aktivitas mendaki, padahal

deteksi yang akurat sangat krusial untuk memantau tingkat kelelahan (*fatigue*) fisik guna mencegah risiko kecelakaan di medan ekstrem (Khan et al., 2025).

Permasalahan ambiguitas sinyal tersebut diperparah oleh keterbatasan pendekatan komputasi konvensional. Metode *Machine Learning* klasik seperti *Support Vector Machine* (SVM) atau *Random Forest* (RF) memiliki kelemahan fundamental, yaitu ketergantungan mutlak pada ekstraksi fitur secara manual (*hand-crafted features*). Proses perumusan fitur ini sangat bergantung pada keahlian domain peneliti dan seringkali gagal menghasilkan representasi data yang optimal dibandingkan kemampuan ekstraksi otomatis yang dimiliki oleh *Deep Learning* (Yin et al., 2024). Lebih lanjut, tinjauan literatur terbaru tahun 2025 menegaskan bahwa meskipun metode konvensional lebih ringan secara komputasi, metode ini sangat rentan mengalami degradasi akurasi saat dihadapkan pada data sensor yang kompleks dan dinamis. Sebaliknya, pendekatan berbasis *Deep Learning* terbukti lebih unggul dalam menangkap pola non-linear dan fitur hirarkis dari aktivitas manusia yang rumit tanpa memerlukan intervensi manusia dalam pemilihan fitur (Dutta et al., 2025).

Sebagai solusi, era Deep Learning menawarkan pendekatan ekstraksi fitur otomatis yang lebih efisien. Convolutional Neural Networks (CNN) 1D telah terbukti andal dalam mengenali fitur spasial dari data sensor mentah. Namun, penelitian eksperimental terbaru menyoroti keterbatasan fatal CNN saat bekerja secara mandiri, yaitu ketidakmampuannya menangkap dependensi jangka panjang (*long-term dependencies*) dari data deret waktu yang kompleks seperti aktivitas fisik berdurasi lama, di mana model seringkali kehilangan konteks urutan Gerakan (Akinola et al., 2024).

Untuk mengatasi celah tersebut, arsitektur Hybrid yang menggabungkan CNN dengan (TRANSFORMER) telah menjadi standar baru dalam riset HAR tahun 2024. Dalam arsitektur ini, CNN bertugas mengekstraksi fitur spasial lokal yang robust terhadap noise, sementara TRANSFORMER memproses fitur tersebut untuk mempelajari dinamika temporal antar langkah. Pengujian empiris membuktikan bahwa integrasi kedua model ini (Hybrid CNN-TRANSFORMER) mampu menghasilkan akurasi klasifikasi yang jauh lebih tinggi dibandingkan jika

kedua model tersebut dijalankan secara terpisah, terutama pada dataset aktivitas yang melibatkan transisi gerakan yang rumit (Sharma et al., 2024).

Selain aspek algoritma, terdapat celah penelitian (research gap) yang signifikan pada aspek pemanfaatan sensor. Penggunaan akselerometer tunggal dinilai tidak lagi memadai untuk membedakan perubahan elevasi vertikal secara akurat. Penelitian eksperimental terbaru tahun 2024 merekomendasikan integrasi sensor inersia multimodal dan penerapan model kecerdasan buatan (Artificial Intelligence) sebagai solusi valid untuk mendeteksi pola aktivitas manusia yang kompleks. Studi tersebut membuktikan bahwa pendekatan fusi sensor berbasis AI mampu meningkatkan akurasi pengenalan aktivitas secara signifikan dibandingkan metode konvensional (Alarfaj et al., 2024).

Berdasarkan paparan tersebut, penelitian ini mengajukan hipotesis bahwa akurasi deteksi aktivitas pendakian dapat ditingkatkan melalui strategi: (1) *Sensor Fusion* multimodal (Accel, Gyro, Barometer) menggunakan instrumen Phyphox yang telah terbukti memiliki validitas tinggi untuk akuisisi data eksperimental sains dan fisika berbasis smartphone (Kurniawan et al., 2025), dan (2) Penerapan arsitektur *Hybrid* CNN-TRANSFORMER. Integrasi Barometer diharapkan menjadi variabel kunci untuk memisahkan aktivitas datar (*flat*) versus menanjak (*ascending*), sementara arsitektur *Hybrid* bertugas menangani kompleksitas fitur spasial-temporal, menjadikan *smartphone* sebagai alat keselamatan pendaki yang andal.

1.2 Permasalahan Penelitian

1.2.1 Identifikasi Masalah

Berdasarkan latar belakang masalah di atas, identifikasi masalah dalam penelitian ini adalah sebagai berikut:

- a. Adanya ambiguitas yang tinggi dalam membedakan pola gerak antara aktivitas berjalan di bidang datar dan aktivitas mendaki (*ascending*) jika hanya mengandalkan data sensor akselerometer standar, karena keduanya memiliki karakteristik sinyal yang serupa.

- b. Keterbatasan model *Deep Learning* tunggal (hanya menggunakan CNN atau hanya TRANSFORMER) dalam menangani data sensor yang *noisy* dan kompleks. CNN cenderung kurang optimal menangkap urutan waktu yang panjang, sementara TRANSFORMER murni seringkali kesulitan mengekstrak fitur esensial dari data mentah secara efisien.
- c. Belum tersedianya metode *Human Activity Recognition* (HAR) yang dioptimalkan secara spesifik untuk lingkungan berkontur ekstrem seperti jalur pendakian gunung, mengingat mayoritas penelitian yang ada berfokus pada aktivitas di area perkotaan yang datar.

1.2.2 Ruang Lingkup Masalah

Berdasarkan beberapa pokok permasalahan yang telah diuraikan pada identifikasi masalah di atas, maka penelitian dibatasi pada:

- a. Pengambilan data aktivitas dilakukan menggunakan sensor yang terintegrasi pada *smartphone* Android melalui bantuan aplikasi Phyphox.
- b. Jenis sensor yang digunakan dibatasi pada *Accelerometer*, *Gyroscope*, dan *Barometer* (tekanan udara).
- c. Posisi peletakan *smartphone* pada tubuh subjek ditetapkan konsisten (misalnya pada saku celana depan) selama proses pengambilan data.
- d. Aktivitas pendakian yang akan diklasifikasikan difokuskan pada empat kelas utama: berjalan menanjak (*ascending*), berjalan menurun (*descending*), berjalan datar (*flat walking*), dan posisi diam/istirahat (*standing*).
- e. Penelitian ini berfokus pada perancangan, pelatihan, dan evaluasi performa model secara *offline*, dan tidak mencakup pengembangan antarmuka aplikasi *mobile* secara utuh.

1.2.3 Rumusan Masalah

Berdasarkan identifikasi dan pembatasan masalah di atas, maka rumusan masalah yang akan dijawab melalui penelitian ini adalah:

- a. Bagaimana merancang struktur arsitektur model *Hybrid* CNN-TRANSFORMER yang mampu mengekstraksi fitur spasial dari sinyal sensor sekaligus menangkap ketergantungan temporalnya secara simultan?
- b. Apakah penerapan teknik *sensor fusion* dengan menambahkan data dari sensor barometer dapat mengurangi ambiguitas dan meningkatkan akurasi dalam membedakan aktivitas yang memiliki kemiripan pola gerak namun berbeda elevasi?
- c. Seberapa signifikan peningkatan kinerja klasifikasi aktivitas pendakian yang dihasilkan oleh model *Hybrid* CNN-TRANSFORMER yang diusulkan jika dibandingkan dengan kinerja model tunggal CNN atau TRANSFORMER standar?

1.3 Tujuan dan Manfaat Penelitian

Adapun tujuan penulis melakukan penelitian ini adalah sebagai berikut:

- a. Membangun sebuah arsitektur model *Hybrid* CNN-TRANSFORMER yang optimal untuk mengenali pola aktivitas pendakian gunung berbasis data sensor *smartphone*.
- b. Menganalisis efektivitas penggabungan sensor (*sensor fusion*), khususnya peran data tekanan udara dari barometer, dalam meningkatkan presisi klasifikasi aktivitas di medan yang menanjak dan menurun.
- c. Mengevaluasi performa model usulan melalui komparasi kuantitatif terhadap model *baseline* (CNN dan TRANSFORMER yang bekerja secara terpisah) untuk membuktikan keunggulan arsitektur *hybrid*.

1.4 Sistematika Penulisan

Untuk memberikan gambaran yang jelas dan menyeluruh mengenai alur penelitian ini, laporan tesis disusun dengan sistematika sebagai berikut:

BAB I PENDAHULUAN

Bab ini menguraikan konteks latar belakang mengapa penelitian mengenai deteksi aktivitas pendaki ini penting dilakukan. Di dalamnya juga dibahas mengenai identifikasi masalah-masalah yang ada, batasan ruang lingkup agar penelitian tetap fokus, rumusan pertanyaan penelitian, serta tujuan dan manfaat yang ingin dicapai.

BAB II LANDASAN TEORI

Bab ini memaparkan kerangka teori yang menjadi fondasi penelitian. Pembahasan mencakup konsep dasar *Human Activity Recognition* (HAR), karakteristik sensor pada *smartphone* (akselerometer, giroskop, barometer), tinjauan pustaka dari penelitian terdahulu yang relevan, serta penjelasan mendalam mengenai teori algoritma *Convolutional Neural Network* (CNN), (TRANSFORMER), dan konsep penggabungan keduanya (*Hybrid*).

BAB III METODOLOGI PENELITIAN

Bab ini menjelaskan secara rinci tahapan-(Hastuti et al., 2025) teknis pelaksanaan riset. Dimulai dari desain skenario pengambilan data di lapangan, teknik pra-pemrosesan sinyal (*preprocessing*) untuk membersihkan data, perancangan detail arsitektur model *Hybrid* CNN-TRANSFORMER, hingga skenario pengujian dan metrik evaluasi yang digunakan untuk mengukur keberhasilan model.

BAB II

LANDASAN TEORI DAN KERANGKA PEMIKIRAN

2.1 Tinjauan Pustaka

Perkembangan teknologi deteksi aktivitas manusia telah mengalami pergeseran signifikan dari penggunaan metode *Machine Learning* konvensional menuju pendekatan *Deep Learning* yang mampu mengekstraksi fitur secara otomatis. Dalam konteks penelitian ini, tinjauan pustaka diarahkan untuk membedah efektivitas arsitektur *Hybrid* yang menggabungkan kemampuan ekstraksi fitur spasial dan memori temporal.

Beberapa penelitian terdahulu telah berupaya memecahkan masalah klasifikasi aktivitas menggunakan data sensor *accelerometer* dan *gyroscope*, baik secara terpisah maupun digabungkan (*sensor fusion*). Untuk memberikan gambaran posisi penelitian ini di antara penelitian-penelitian yang sudah ada, serta untuk menonjolkan kebaruan (*novelty*) yang ditawarkan, berikut disajikan tabel perbandingan penelitian terdahulu.

Tabel 2 1 Penelitian Terdahulu

No	Aspek	Uraian
1	Peneliti dan Tahun	Yin, Y., et al. (2024)
	Judul Penelitian	A Systematic Review of Human Activity Recognition Based On Mobile Devices: Overview, Progress and Trends
	Penerbit	IEEE Communications Surveys & Tutorials (Jurnal Q1)
	Metode	Tinjauan Sistematis (Systematic Review) terhadap metode HAR berbasis <i>smartphone</i> .
	Hasil Penelitian	Menyimpulkan bahwa metode Machine Learning konvensional (SVM/RF) mulai ditinggalkan karena ketergantungan pada fitur manual, dan digantikan

		oleh Deep Learning (CNN/RNN) yang lebih <i>robust</i> terhadap data sensor yang kompleks.
	Critical Review (Persamaan dan Perbedaan)	Persamaan: Sama-sama membahas HAR berbasis sensor <i>smartphone</i> dan transisi ke Deep Learning. Perbedaan: Penelitian ini adalah <i>review</i> teoritis luas, sedangkan penelitian saya adalah implementasi teknis spesifik (eksperimental) pada kasus pendakian gunung.
2	Peneliti dan Tahun	Dutta, S. J., et al. (2025)
	Judul Penelitian	<i>Human activity recognition: A review of deep learning-based methods</i>
	Penerbit	IET Computer Vision
	Metode	Komparasi arsitektur Deep Learning (CNN, RNN, TRANSFORMER, Hybrid).
	Hasil Penelitian	Menemukan bahwa model Hybrid (gabungan CNN dan TRANSFORMER) memberikan akurasi tertinggi karena mampu mengekstraksi fitur spasial sekaligus mengingat konteks waktu (<i>temporal dependencies</i>).
	Critical Review (Persamaan dan Perbedaan)	Persamaan: Menggunakan metode <i>Hybrid</i> CNN-TRANSFORMER dalam penelitian. Perbedaan: Fokus artikel ini pada visi komputer dan sensor umum, sedangkan penelitian saya memfokuskan pada fusi sensor barometer untuk elevasi.
3	Peneliti dan Tahun	Alarfaj, M., et al. (2024)
	Judul Penelitian	<i>Wearable sensors based on artificial intelligence models for human activity recognition</i>

	Penerbit	Frontiers in Artificial Intelligence
	Metode	Eksperimen AI Model pada sensor <i>wearable</i> untuk deteksi aktivitas fisik.
	Hasil Penelitian	Membuktikan bahwa penggunaan <i>AI/Deep Learning</i> pada sensor <i>wearable</i> mampu meningkatkan akurasi deteksi aktivitas fisik yang kompleks dibandingkan metode statistik biasa.
	Critical Review (Persamaan dan Perbedaan)	Persamaan: Menggunakan pendekatan AI untuk mengenali pola aktivitas fisik. Perbedaan: Penelitian ini menggunakan dataset umum, sedangkan penelitian saya menargetkan aktivitas spesifik "Mendaki" dengan variabel ketinggian.
4	Peneliti dan Tahun	Manivannan, A., et al. (2020)
	Judul Penelitian	<i>On the Challenges and Potential of Using Barometric Sensors to Track Human Activity</i>
	Penerbit	MDPI Sensors
	Metode	Eksperimen pengujian sensor Barometer (tekanan udara) untuk membedakan aktivitas vertikal (naik tangga/lift) vs horizontal.
	Hasil Penelitian	Menemukan bahwa sensor Barometer memiliki potensi besar dan akurasi tinggi untuk mendeteksi perubahan elevasi vertikal yang tidak bisa dideteksi oleh akselerometer saja.
	Critical Review (Persamaan dan Perbedaan)	Persamaan: Mendukung hipotesis penelitian ini bahwa Barometer adalah kunci untuk membedakan aktivitas "Mendaki". Perbedaan:

		Penelitian ini fokus pada analisis karakteristik sensor (<i>sensor behavior</i>), sedangkan penelitian saya fokus pada integrasi datanya ke dalam model <i>Deep Learning</i> .
5	Peneliti dan Tahun	Kurniawan, A., et al. (2025)
	Judul Penelitian	<i>Development and Validation of Free Fall Motion Experiment Kit Based on Arduino UNO and Phyphox Application</i>
	Penerbit	Jurnal Pendidikan MIPA
	Metode	Uji validitas dan reliabilitas sensor <i>smartphone</i> menggunakan aplikasi Phyphox.
	Hasil Penelitian	Instrumen Phyphox terbukti valid (kategori sangat baik) untuk mengambil data fisika yang presisi.
	Critical Review (Persamaan dan Perbedaan)	Persamaan: Menggunakan <i>tools</i> akuisisi data yang sama yaitu aplikasi Phyphox. Perbedaan: Objek penelitian mereka adalah gerak jatuh bebas (fisika dasar), sedangkan penelitian saya menggunakan datanya untuk <i>training</i> model AI pola pendakian.
6	Peneliti dan Tahun	Sharma, A., et al. (September 2024)
	Judul Penelitian	<i>Human Activity Recognition Using CNN-TRANSFORMER</i>
	Penerbit	Computer Science, Engineering and Technology
	Metode	Implementasi algoritma CNN-TRANSFORMER pada dataset HAR standar (UCI HAR).
	Hasil Penelitian	Model CNN-TRANSFORMER mencapai akurasi 94.5%, mengungguli model Machine Learning tradisional dan CNN tunggal.

	Critical Review (Persamaan dan Perbedaan)	Persamaan: Menggunakan algoritma inti yang sama persis (CNN-TRANSFORMER). Perbedaan: Mereka menggunakan dataset publik yang sudah bersih (UCI HAR), sedangkan penelitian saya menggunakan <i>custom dataset</i> (data sendiri) yang diambil langsung di lapangan.
7	Peneliti dan Tahun	Akinola, D. (Desember 2024)
	Judul Penelitian	<i>A Deep Learning-based Hybrid CNN-TRANSFORMER Model for Human Activity Recognition</i>
	Penerbit	International Journal of Scientific Research in Computer Science and Engineering
	Metode	Pengembangan model Hybrid untuk mengatasi kelemahan CNN dalam menangkap data <i>time-series</i> .
	Hasil Penelitian	Hybrid CNN-TRANSFORMER efektif menangkap fitur spasial dan temporal secara bersamaan.
	Critical Review (Persamaan dan Perbedaan)	Persamaan: Fokus pada arsitektur Hybrid untuk data deret waktu. Perbedaan: Penelitian ini lebih berat ke analisis teknis arsitektur model, sedangkan penelitian saya lebih berat ke aplikasi praktis (keselamatan pendaki).
8	Peneliti dan Tahun	Muladi, et al. (Desember 2024)
	Judul Penelitian	<i>LoRa Mesh-Based IoT GPS Tracking System for Mountain Climbers</i>
	Penerbit	International Journal of Safety and Security Engineering
	Metode	Pengembangan alat pelacak berbasis IoT LoRa Mesh untuk komunikasi tanpa sinyal seluler.

	Hasil Penelitian	Berhasil mengirim koordinat GPS antar <i>node</i> , namun tetap
	Critical Review (Persamaan dan Perbedaan)	Persamaan: Sama-sama meneliti teknologi keselamatan untuk pendaki gunung. Perbedaan: Penelitian mereka fokus pada Konektivitas/Kiriman Data (IoT Hardware), sedangkan penelitian saya fokus pada Kecerdasan Buatan/Analisis Gerak (Software AI) yang tidak butuh koneksi sama sekali.
9	Peneliti dan Tahun	Penchalaiah, K., et al. (2025)
	Judul Penelitian	<i>Smart Jacket for Health Monitoring of Climbers Using LoRaWAN Technology</i>
	Penerbit	JETIR (Journal of Emerging Technologies and Innovative Research)
	Metode	Pembuatan prototipe jaket dengan sensor detak jantung dan suhu berbasis LoRaWAN.
	Hasil Penelitian	Jaket dapat memantau tanda vital dan mengirim peringatan ke stasiun pemantau.
	Critical Review (Persamaan dan Perbedaan)	Persamaan: Topik keselamatan pendaki (<i>safety monitoring</i>). Perbedaan: Solusi penelitian mereka bergantung pada alat khusus (Jaket) dan jaringan LoRa, sedangkan solusi penelitian saya lebih praktis (hanya pakai HP yang sudah dimiliki pendaki) dan menganalisis pola langkah, bukan hanya detak jantung.
10	Peneliti dan Tahun	Sonawane, M., et al. (2024)
	Judul Penelitian	<i>IoT Based Mountain Climber Health and Position Tracker</i>

	Penerbit	IJAR SCT (International Journal of Advanced Research in Science, Communication and Technology)
	Metode	Sistem pelacak berbasis NodeMCU ESP8266 dan Cloud Server.
	Hasil Penelitian	Data kesehatan dikirim ke <i>cloud</i> untuk dipantau.
	Critical Review (Persamaan dan Perbedaan)	Persamaan: Tujuan mitigasi risiko kecelakaan di gunung. Perbedaan: Sistem ini sangat bergantung pada Internet (Cloud) yang seringkali mati di area <i>blank spot</i>, sedangkan sistem saya dirancang Offline (Edge Computing) sehingga lebih andal di hutan rimba.

2.2 Landasaan Teori

Sub bab ini menyajikan kerangka teoretis yang menjadi fondasi utama dalam perancangan dan analisis sistem. Pembahasan diawali dengan konsep *Human Activity Recognition* (HAR) dan *Sensor Fusion* sebagai basis metode pengenalan aktivitas, serta pemanfaatan aplikasi Phyphox untuk akuisisi data. Selanjutnya, diuraikan paradigma *Machine Learning* dan *Deep Learning* yang menjadi landasan algoritma, dengan fokus spesifik pada arsitektur *Convolutional Neural Network* (CNN), TRANSFORMER, hingga penggabungan keduanya dalam model *Hybrid CNN-TRANSFORMER*. Sebagai penutup, bab ini juga menjabarkan perangkat pengembangan yang digunakan dalam implementasi sistem, yaitu bahasa pemrograman Python dan editor *Visual Studio Code*.

2.2.1 *Human Activity Recognition* (HAR)

Human Activity Recognition (HAR) adalah sebuah proses klasifikasi untuk memahami perilaku manusia. Sistem ini bekerja dengan cara memprediksi dan mengelompokkan jenis aktivitas atau gerakan tubuh seseorang berdasarkan data yang ditangkap oleh teknologi, baik itu menggunakan sensor (seperti akselerometer

dan giroskop pada ponsel) maupun melalui kamera video (Abdullah & Ahmed, 2024).

2.2.2 Sensor Fusion

Sensor Fusion pada dasarnya adalah sebuah strategi algoritma yang bertugas untuk "mengawinkan" atau menggabungkan data dari beberapa jenis sensor yang berbeda (Sungkono et al., 2023).

Accelerometer merupakan sensor yang mendeteksi arah dan intensitas gerakan perangkat dengan mengukur percepatan linear (termasuk gravitasi). *Gyroscope* merupakan sensor yang mengukur rotasi perangkat pada sumbu Cartesian (X, Y, Z) (Caro-Alvaro et al., 2024). *Accelerometer* sebagai alat ukur percepatan linear. *Gyroscope* sebagai alat pengukur kecepatan sudut (*angular velocity*) (Ali et al., 2024).

2.2.3 Aplikasi Phyphox

Phyphox, yang merupakan singkatan dari *Physical Phone Experiments*, adalah sebuah aplikasi yang dikembangkan oleh RWTH Aachen untuk mengubah *smartphone* menjadi alat eksperimen fisika dengan cara membaca dan memanfaatkan sensor-sensor internal yang sudah ada di dalam perangkat tersebut. Aplikasi ini tidak hanya sekedar mengambil data sensor, tetapi juga mampu mengolahnya menjadi grafik atau data secara *real-time*, melakukan analisis data langsung di dalam aplikasi, serta memungkinkan kontrol jarak jauh (*remote access*) agar eksperimen tetap bisa diamati meskipun ponsel berada di posisi yang sulit dijangkau (Imtinan & Kuswanto, 2023).

2.2.4 Deep Learning

Deep Learning sebagai evolusi dari sistem jaringan saraf tiruan. Ia adalah cabang AI yang tidak sekedar memproses data, tapi benar-benar meniru cara kerja biologis otak manusia lewat lapisan-lapisan algoritma yang rumit. Karena

kedalaman lapisannya inilah ia sering disebut *Deep Neural Networks* (DNN), yang memungkinkannya memecahkan masalah dan pola yang sulit dipahami oleh komputer biasa (Hastuti et al., 2025).

2.2.5 Machine Learning

Machine Learning diklasifikasikan ke dalam tiga metode pendekatan. Pendekatan pertama, *Supervised Learning*, memanfaatkan data berlabel untuk melatih model agar mampu memprediksi *output* yang akurat, seperti pada kasus deteksi spam atau analisis pasar saham. *Unsupervised Learning* berfokus pada eksplorasi data tanpa label untuk mengungkap struktur atau pola implisit, yang sering diaplikasikan dalam segmentasi pasar maupun penyederhanaan data. Kategori terakhir, *Reinforcement Learning*, berbeda secara fundamental karena melibatkan agen yang belajar beradaptasi melalui interaksi langsung dengan lingkungan untuk mengoptimalkan pencapaian *reward* secara kumulatif (Ade Ryan Pratama et al., 2025).

2.2.6 Convolutional Neural Network (CNN)

Convolutional Neural Network (CNN) merupakan salah satu metode dalam *deep learning* yang dikembangkan dari *Multilayer Perceptron* (MLP) dan dirancang khusus untuk menganalisis data dua dimensi, seperti gambar atau suara. Algoritma ini menerapkan pendekatan pembelajaran terawasi (*supervised learning*), di mana sistem mengklasifikasikan data input ke dalam kategori yang telah ditentukan sebelumnya menggunakan data latih yang sudah memiliki label (Fahmi et al., 2025).

Convolutional Neural Network (CNN) didefinisikan sebagai jenis jaringan saraf tiruan yang digunakan secara luas dalam *deep learning*, khususnya untuk tugas pemrosesan citra. Secara fundamental, arsitektur CNN tersusun atas tiga blok utama: lapisan konvolusi, lapisan *pooling*, dan lapisan *fully connected*. Lapisan konvolusi bertugas mendeteksi fitur lokal pada data input menggunakan filter yang dapat dilatih, sementara lapisan *pooling* berfungsi mereduksi dimensi matriks input


untuk efisiensi komputasi. Proses klasifikasi akhir kemudian dilakukan oleh lapisan *fully connected* berdasarkan fitur-fitur yang telah diekstraksi tersebut.(Yilmaz & Kuş, 2026)

2.2.7 (TRANSFORMER)

(TRANSFORMER) adalah pengembangan dari arsitektur *Recurrent Neural Network* (RNN) yang diciptakan untuk mengatasi kelemahan RNN konvensional, terutama masalah *vanishing gradient*. Keunggulan utama TRANSFORMER terletak pada struktur memori khususnya yang mampu menyimpan informasi dalam jangka waktu lama. Kemampuan ini menjadikannya sangat andal dalam menganalisis data *time series* yang kompleks, termasuk mendeteksi pola musiman dan tren jangka panjang secara lebih akurat (Simanjuntak et al., 2025).

2.2.8 Arsitektur Hybrid CNN-TRANSFORMER

Model *Hybrid CNN-TRANSFORMER* merupakan pendekatan komputasi yang menggabungkan kemampuan pemrosesan sekuensial dan visual. Secara konseptual, model ini membagi tugas prediksi ke dalam dua tahap khusus: jaringan TRANSFORMER bertugas memprediksi parameter fisika yang berubah terhadap waktu (seperti koefisien gaya angkat), yang kemudian hasilnya digunakan sebagai basis data bagi jaringan CNN untuk merekonstruksi distribusi spasial secara menyeluruh. Pendekatan ini didasari oleh prinsip bahwa penambahan informasi temporal yang akurat dari TRANSFORMER dapat meningkatkan performa CNN dalam memvisualisasikan karakteristik aliran yang kompleks (Portal-Porras et al., 2023).



Gambar 2 1 Arsitektur CNN-TRANSFORMER

2.2.9 Python

Python merupakan bahasa pemrograman yang semakin populer digunakan dalam komputasi ilmiah. Popularitas ini didorong oleh karakteristik bahasanya yang sederhana dan memiliki tingkat keterbacaan (*readability*) yang tinggi. Selain itu, Python didukung oleh ekosistem pustaka (*library*) yang luas, khususnya untuk kebutuhan pemrosesan numerik dan visualisasi data (Venter & Neaves, 2025).

Python didefinisikan sebagai bahasa pemrograman modern tingkat tinggi (*high-level programming language*) yang bersifat gratis dan sumber terbuka (*open-source*). Karakteristik keterbukaan dan kemudahan akses ini menjadikan Python sebagai salah satu bahasa pemrograman yang diadopsi secara luas, baik dalam ranah pendidikan sains maupun untuk keperluan penelitian ilmiah orisinal (Völker et al., 2025).

2.2.10 Visual Studio Code

Visual Studio Code berfungsi sebagai lingkungan pengembangan untuk merancang dan membangun simulasi berbasis *web*. Penggunaan editor ini memungkinkan pengembang untuk menyusun struktur kode program yang diperlukan dalam menciptakan sistem simulasi prosedur teknis agar dapat berjalan secara interaktif dan efektif (Nyoman et al., 2025).


2.3 Kerangka Pemikiran

Kerangka pemikiran dalam penelitian ini dibangun berdasarkan kebutuhan untuk menciptakan sistem pemantauan aktivitas fisik yang efisien dan akurat, khususnya bagi para pendaki gunung. Aktivitas pendakian memiliki risiko tinggi, sehingga pengenalan aktivitas secara *real-time* menjadi krusial untuk aspek keselamatan. Namun, tantangan utama yang dihadapi adalah bagaimana mengolah data gerak yang kompleks dan fluktuatif menjadi informasi yang bermakna.

Untuk menjawab tantangan tersebut, penelitian ini memanfaatkan teknologi *smartphone* yang telah terintegrasi dengan sensor inersia, yakni *accelerometer* dan *gyroscope*. Pengambilan data sensor dilakukan menggunakan aplikasi Phyphox yang memungkinkan akuisisi data mentah secara presisi. Mengingat data sensor sering kali mengandung *noise* atau gangguan, pendekatan *Sensor Fusion* diterapkan pada tahap pra-pemrosesan. Teknik ini bertujuan menggabungkan keunggulan dari kedua sensor untuk menghasilkan data orientasi dan gerakan yang lebih stabil dan akurat dibandingkan jika hanya mengandalkan satu jenis sensor.

Pada tahap pemrosesan dan klasifikasi, penelitian ini mengadopsi pendekatan *Deep Learning* dengan arsitektur hibrida, yaitu *Hybrid CNN-TRANSFORMER*. Pemilihan arsitektur ini didasarkan pada karakteristik data aktivitas manusia yang memiliki dimensi spasial dan temporal. Algoritma *Convolutional Neural Network* (CNN) bertugas mengekstraksi fitur-fitur spasial yang unik dari pola sinyal sensor, sedangkan (TRANSFORMER) berperan dalam menangkap ketergantungan waktu (*temporal dependencies*) dari urutan gerakan tersebut.

Seluruh implementasi sistem, mulai dari pengolahan data hingga pembangunan model, dikembangkan menggunakan bahasa pemrograman Python dalam lingkungan kerja *Visual Studio Code*. Hasil akhir yang diharapkan dari alur pemikiran ini adalah sebuah model sistem *Human Activity Recognition* (HAR) yang memiliki tingkat akurasi tinggi dalam mengklasifikasikan aktivitas pendakian, yang nantinya dapat dikembangkan lebih lanjut sebagai fitur keselamatan berbasis teknologi.



Gambar 2.2 Kerangka Pemikiran

BAB III METODOLOGI

3.1 Analisis Kebutuhan

Tahap ini berfokus pada identifikasi kebutuhan perangkat keras (*hardware*) dan perangkat lunak (*software*) yang diperlukan untuk mendukung seluruh rangkaian eksperimen dan pengembangan sistem *Human Activity Recognition* (HAR).

3.1.1 Kebutuhan Perangkat Keras

Perangkat keras utama yang digunakan dalam penelitian ini adalah unit komputasi untuk pemrosesan data dan perangkat *mobile* untuk akuisisi data. Spesifikasi minimum yang digunakan meliputi:

- a. Smartphone: Dilengkapi dengan sensor *Inertial Measurement Unit* (IMU), khususnya *accelerometer* dan *gyroscope*, untuk merekam data gerak aktivitas fisik.
- b. Laptop/PC: Digunakan untuk proses *coding*, pelatihan model (*training*), dan evaluasi. Disarankan memiliki GPU (seperti NVIDIA) untuk mempercepat proses komputasi *Deep Learning*, atau setidaknya prosesor setara Intel Core i5/AMD Ryzen 5 dengan RAM minimal 8GB.

3.1.2 Kebutuhan Perangkat Lunak

Lingkungan pengembangan sistem dibangun menggunakan beberapa perangkat lunak berikut:

- a. Aplikasi Phyphox: Digunakan pada *smartphone* sebagai *tool* akuisisi data untuk mengakses, merekam, dan mengeksport data mentah dari sensor *accelerometer* dan *gyroscope* dalam format .CSV.
- b. Sistem Operasi: Windows 10/11 atau Linux (Ubuntu) sebagai lingkungan kerja utama.
- c. Visual Studio Code (VS Code): Berfungsi sebagai *Integrated Development Environment* (IDE) atau editor kode utama untuk penulisan skrip program.

- d. Bahasa Pemrograman Python: Dipilih karena memiliki ekosistem pustaka yang luas untuk *Data Science* dan *Machine Learning*.
- e. Pustaka Pendukung (*Libraries*):
 - *Pandas & NumPy*: Untuk manipulasi data matriks dan *dataframe*.
 - *Scikit-learn*: Untuk pra-pemrosesan data dan evaluasi metrik.
 - *TensorFlow/Keras* atau *PyTorch*: Untuk membangun dan melatih arsitektur *Hybrid CNN-TRANSFORMER*.
 - *Matplotlib/Seaborn*: Untuk visualisasi grafik hasil pelatihan dan sinyal sensor.

3.2 Perancangan Penelitian

Perancangan penelitian ini mengikuti alur kerja sistematis yang terdiri dari empat tahapan utama: pengumpulan data, pra-pemrosesan, pembangunan model, dan evaluasi.

3.2.1 Pengumpulan Data (*Data Acquisition*)

Proses pengambilan data dilakukan dengan melibatkan subjek penelitian yang melakukan simulasi aktivitas pendakian (seperti berjalan datar, menanjak, menuruni bukit, atau kondisi diam). *Smartphone* yang telah terinstal aplikasi Phyphox diletakkan pada posisi yang tetap dan stabil (misalnya di saku celana atau *waist bag*) untuk meminimalkan gangguan (*noise*) akibat guncangan yang tidak relevan. Data direkam dengan frekuensi sampling tertentu (misalnya 50Hz) untuk menangkap detail gerakan secara akurat.

3.2.2 Pra-pemrosesan Data (*Data Preprocessing*)

Data mentah dari sensor tidak dapat langsung diproses oleh model karena sering kali mengandung *noise* dan memiliki rentang nilai yang berbeda. Oleh karena itu, dilakukan tahapan berikut:

- a. Pembersihan Data: Menghapus data awal dan akhir rekaman yang tidak relevan (fase persiapan alat).

- b. Sensor Fusion: Menggabungkan data percepatan (*acceleration*) dan kecepatan sudut (*angular velocity*) menggunakan algoritma fusi (seperti *Complementary Filter* atau *Kalman Filter*) atau penggabungan fitur (*feature concatenation*) untuk mendapatkan representasi orientasi tubuh yang lebih stabil.
- c. Normalisasi: Mengubah skala data ke dalam rentang $[0, 1]$ atau $[-1, 1]$ menggunakan teknik *Min-Max Scaling* atau *Standard Scaler* agar proses pelatihan model lebih cepat konvergen.
- d. Segmentasi (Sliding Window): Memotong data urutan waktu (*time-series*) menjadi jendela-jendela kecil (*windows*) dengan durasi tetap (misalnya 2-5 detik) dan *overlap* tertentu (misalnya 50%). Teknik ini penting agar model CNN-TRANSFORMER dapat mempelajari pola transisi antar gerakan.

3.2.3 Arsitektur Model Hybrid CNN-TRANSFORMER

Perancangan model menggunakan pendekatan hibrida yang menggabungkan dua lapisan utama:

- a. Lapisan CNN (*Convolutional Layer*): Berfungsi sebagai ekstraktor fitur otomatis. Lapisan ini akan memindai data input lokal untuk menemukan pola spasial yang unik dari sinyal sensor.
- b. Lapisan TRANSFORMER (*Recurrent Layer*): *Output* dari CNN kemudian diteruskan ke lapisan TRANSFORMER. Di sini, sistem akan mempelajari ketergantungan temporal jangka panjang, atau bagaimana satu gerakan berkaitan dengan gerakan sebelumnya dalam urutan waktu.
- c. Lapisan Klasifikasi (*Dense Layer*): Hasil akhir dari TRANSFORMER diproses oleh lapisan *Fully Connected* dengan fungsi aktivasi *Softmax* untuk menentukan probabilitas kelas aktivitas (misalnya: mendaki, berjalan, jatuh).

3.3 Teknik Analisis

Untuk mengukur keberhasilan model yang dibangun, teknik analisis kuantitatif diterapkan menggunakan metode *Confusion Matrix*. Evaluasi dilakukan

dengan membandingkan prediksi model terhadap data aktual (*ground truth*) pada data uji (*testing set*). Parameter kinerja yang diukur meliputi:

- a. Akurasi (*Accuracy*): Rasio total prediksi yang benar terhadap keseluruhan data sampel.
- b. Presisi (*Precision*): Tingkat ketepatan model dalam memprediksi kelas positif (aktivitas tertentu).
- c. Recall (Sensitivitas): Kemampuan model dalam menemukan kembali seluruh data positif yang sebenarnya ada.
- d. F1-Score: Rata-rata harmonis antara presisi dan *recall*, yang sangat berguna jika terdapat ketidakseimbangan jumlah data antar kelas aktivitas.

Analisis ini bertujuan untuk membuktikan bahwa integrasi *Sensor Fusion* dan arsitektur *Hybrid CNN-TRANSFORMER* mampu meningkatkan performa sistem dibandingkan dengan metode konvensional.

BAB IV HASIL DAN PEMBAHASAN

4.1 Hasil Eksperimen

Pada tahap ini, dilakukan pengujian terhadap model Hybrid CNN-Transformer untuk mengklasifikasikan pola aktivitas pendaki gunung. Berdasarkan ringkasan model, sistem memiliki 185,862 parameter yang dapat dilatih, yang menunjukkan efisiensi model dalam melakukan ekstraksi fitur dari 561 variabel sensor fusion.

Layer (type)	Output Shape	Param #	Connected to
input_layer (InputLayer)	(None, 1, 561)	0	-
conv1d (Conv1D)	(None, 1, 64)	35,968	input_layer[0][0]
dropout (Dropout)	(None, 1, 64)	0	conv1d[0][0]
layer_normalization (LayerNormalizatio...	(None, 1, 64)	128	dropout[0][0]
multi_head_attenti... (MultiHeadAttentio...	(None, 1, 64)	132,672	layer_normalizat... layer_normalizat...
add (Add)	(None, 1, 64)	0	multi_head_atten... dropout[0][0]
layer_normalizatio... (LayerNormalizatio...	(None, 1, 64)	128	add[0][0]
conv1d_1 (Conv1D)	(None, 1, 128)	8,320	layer_normalizat...
conv1d_2 (Conv1D)	(None, 1, 64)	8,256	conv1d_1[0][0]
add_1 (Add)	(None, 1, 64)	0	conv1d_2[0][0], add[0][0]
global_average_poo... (GlobalAveragePool...	(None, 64)	0	add_1[0][0]
dense (Dense)	(None, 6)	390	global_average_p...

Gambar 4 1 Ringkasan Arsitektur Model Hybrid CNN-TRANSFORMER

Gambar diatas menunjukan bahwa arsitektur model Hybrid CNN-Transformer yang dirancang khusus untuk menangani data deret waktu atau sensor fusion dengan struktur yang sangat sistematis dan efisien. Alur pemrosesan dimulai dari

input_layer yang menerima 561 fitur sensor, diikuti oleh lapisan Conv1D untuk ekstraksi fitur spasial awal, dan diperkuat dengan mekanisme Multi-Head Attention yang memungkinkan model menangkap dependensi fitur yang kompleks secara simultan. Arsitektur ini juga menerapkan teknik modern seperti *Layer Normalization* dan *Residual Connections* (melalui lapisan add) untuk menjaga stabilitas gradien selama pelatihan, serta diakhiri dengan GlobalAveragePooling1D dan lapisan Dense dengan 6 output yang merepresentasikan klasifikasi aktivitas target. Dengan total parameter yang dapat dilatih sebanyak 185.862, model ini menawarkan keseimbangan yang optimal antara kompleksitas arsitektur dan efisiensi komputasi, menjadikannya solusi yang sangat tangguh untuk pengenalan aktivitas manusia berbasis sensor.

4.2 Analisis Proses Pelatihan

Proses pelatihan dilakukan selama 15 epoch untuk melihat kestabilan akurasi dan penurunan nilai *loss*. Hasil menunjukkan konvergensi yang cepat sejak epoch ke-6.

```
230/230 ————— 12s 23ms/step - accuracy: 0.6658 - loss: 0.8267 - val_accu
racy: 0.8894 - val_loss: 0.2788
Epoch 2/15
230/230 ————— 1s 4ms/step - accuracy: 0.8889 - loss: 0.2756 - val_accu
cy: 0.8646 - val_loss: 0.3163
Epoch 3/15
230/230 ————— 1s 4ms/step - accuracy: 0.9165 - loss: 0.2035 - val_accu
cy: 0.8795 - val_loss: 0.3503
Epoch 4/15
230/230 ————— 1s 4ms/step - accuracy: 0.9255 - loss: 0.1836 - val_accu
cy: 0.9169 - val_loss: 0.2151
Epoch 5/15
230/230 ————— 1s 4ms/step - accuracy: 0.9461 - loss: 0.1460 - val_accu
cy: 0.9267 - val_loss: 0.2385
Epoch 6/15
230/230 ————— 1s 4ms/step - accuracy: 0.9453 - loss: 0.1470 - val_accu
cy: 0.9467 - val_loss: 0.1420
Epoch 7/15
230/230 ————— 1s 4ms/step - accuracy: 0.9404 - loss: 0.1482 - val_accu
cy: 0.9552 - val_loss: 0.1194
Epoch 8/15
230/230 ————— 1s 4ms/step - accuracy: 0.9525 - loss: 0.1286 - val_accu
cy: 0.9287 - val_loss: 0.1812
Epoch 9/15
230/230 ————— 1s 4ms/step - accuracy: 0.9565 - loss: 0.1113 - val_accu
cy: 0.9125 - val_loss: 0.2683
```

```

230/230 ————— 1s 4ms/step - accuracy: 0.9565 - loss: 0.1113 - val_accu-
cy: 0.9125 - val_loss: 0.2683
Epoch 10/15
230/230 ————— 1s 4ms/step - accuracy: 0.9505 - loss: 0.1243 - val_accu-
cy: 0.9406 - val_loss: 0.1784
Epoch 11/15
230/230 ————— 1s 4ms/step - accuracy: 0.9526 - loss: 0.1287 - val_accu-
cy: 0.9467 - val_loss: 0.1765
Epoch 12/15
230/230 ————— 1s 4ms/step - accuracy: 0.9525 - loss: 0.1222 - val_accu-
cy: 0.9321 - val_loss: 0.2615
Epoch 13/15
230/230 ————— 1s 4ms/step - accuracy: 0.9623 - loss: 0.1015 - val_accu-
cy: 0.9379 - val_loss: 0.1917
Epoch 14/15
230/230 ————— 1s 4ms/step - accuracy: 0.9571 - loss: 0.1081 - val_accu-
cy: 0.9362 - val_loss: 0.2231
Epoch 15/15
230/230 ————— 1s 4ms/step - accuracy: 0.9641 - loss: 0.0941 - val_accu-
cy: 0.9365 - val_loss: 0.2141

```

Gambar 4 2 Grafik perbandingan antara akurasi training dengan validasi dan loss training dengan validasi selama 15 epoch


Gambar diatas menampilkan log proses pelatihan model machine learning menggunakan library TensorFlow/Keras selama 15 epoch, yang menunjukkan performa model yang sangat positif dan stabil dalam mengklasifikasikan aktivitas pendaki gunung. Pada awal pelatihan (Epoch 1), model memulai dengan akurasi data training sebesar 66,58% dan akurasi validasi 88,94%, namun meningkat secara signifikan dan mencapai kestabilan (konvergensi) yang cepat sejak epoch ke-7 dengan akurasi validasi menyentuh 95,52%. Hingga akhir sesi pada Epoch 15, model berhasil mencapai akurasi training maksimal sebesar 96,41% dengan nilai loss yang rendah di angka 0,0941, sementara akurasi validasi tetap terjaga di angka 93,65%. Tren penurunan nilai loss yang konsisten disertai peningkatan akurasi pada kedua dataset (training dan validation) mengindikasikan bahwa arsitektur Hybrid CNN-Transformer yang digunakan sangat efektif dalam mempelajari pola fitur sensor fusion tanpa mengalami indikasi overfitting yang parah, sehingga model ini memiliki kemampuan generalisasi yang baik untuk diimplementasikan pada data baru.

4.3 Evaluasi Performa Model

Evaluasi dilakukan menggunakan data uji (*test data*) yang belum pernah dilihat oleh model sebelumnya untuk memastikan kemampuan generalisasi arsitektur Hybrid ini.

4.3.1 Confusion Matrix

Confusion Matrix digunakan untuk memvisualisasikan distribusi prediksi aktivitas.



Gambar 4 3 Confusion Matri

Gambar tersebut menampilkan *Confusion Matrix* yang memvisualisasikan performa model dalam mengklasifikasikan enam jenis aktivitas pendaki gunung, di mana intensitas warna biru yang pekat pada garis diagonal menunjukkan tingkat akurasi prediksi yang sangat tinggi. Model menunjukkan performa sempurna pada aktivitas Laying dengan 537 prediksi benar tanpa kesalahan, serta performa yang

sangat kuat pada aktivitas dinamis seperti Walking dan Walking Upstairs. Meskipun secara keseluruhan sangat akurat, matriks ini mengungkap adanya tantangan kecil pada aktivitas statis, terlihat dari 81 data Sitting yang terprediksi sebagai Standing, serta pada aktivitas transisi di mana 49 data Walking Downstairs teridentifikasi sebagai Walking Upstairs. Fenomena ini umum terjadi dalam pengenalan aktivitas manusia karena kemiripan pola sinyal sensor pada posisi tubuh yang serupa, namun dominasi angka pada garis diagonal mengonfirmasi bahwa model Hybrid CNN-Transformer ini memiliki reliabilitas yang tinggi dalam membedakan berbagai pola pergerakan pendaki.

4.3.2 Laporan Klasifikasi

Berikut adalah tabel performa model berdasarkan metrik *Precision*, *Recall*, dan *F1-Score* yang diperoleh dari pengujian akhir:

	precision	recall	f1-score	support
LAYING	1.00	1.00	1.00	537
SITTING	0.96	0.83	0.89	491
STANDING	0.86	0.97	0.92	532
WALKING	0.93	0.99	0.96	496
WALKING_DOWNSTAIRS	0.99	0.83	0.91	420
WALKING_UPSTAIRS	0.90	0.97	0.93	471
accuracy			0.94	2947
macro avg	0.94	0.93	0.93	2947
weighted avg	0.94	0.94	0.94	2947

Gambar 4 4 Laporan Klasifikasi Metrik Evaluasi Per-Aktivitas

Gambar tersebut menyajikan ringkasan performa model melalui laporan klasifikasi (*Classification Report*) yang mencakup metrik evaluasi krusial seperti *precision*, *recall*, dan *f1-score* untuk setiap kategori aktivitas pendaki gunung. Secara keseluruhan, model menunjukkan efektivitas yang sangat tinggi dengan akurasi total mencapai 94% dari total 2.947 sampel uji, di mana aktivitas Laying berhasil diklasifikasikan dengan sempurna

dengan nilai 1.00 pada semua metrik utama. Selain itu, model menunjukkan keandalan dalam mendeteksi aktivitas dinamis seperti Walking dan Walking Upstairs yang memiliki nilai *recall* masing-masing sebesar 0.99 dan 0.97, menandakan bahwa sistem sangat jarang melewatkan deteksi pada pola gerakan tersebut. Meskipun terdapat sedikit variasi pada aktivitas statis seperti Standing dan Sitting yang memiliki nilai f1-score sedikit di bawah rata-rata karena kemiripan pola data sensor, perolehan nilai *weighted average* yang konsisten di angka 0.94 membuktikan bahwa arsitektur *Hybrid CNN-Transformer* yang Anda kembangkan memiliki kemampuan generalisasi yang solid dan layak untuk diimplementasikan dalam skenario pemantauan aktivitas pendaki gunung secara nyata.

BAB V PENUTUP

5.1 Kesimpulan

Berdasarkan hasil penelitian, implementasi, dan pengujian yang telah dilakukan pada model *Hybrid CNN-Transformer* untuk analisis spasial-temporal pola aktivitas pendaki gunung, maka dapat ditarik beberapa kesimpulan utama sebagai berikut:

1. Penggabungan arsitektur *Convolutional Neural Network* (CNN) dan *Transformer* terbukti sangat efektif dalam menangani data *sensor fusion*. CNN berhasil menjalankan perannya dalam mengekstraksi fitur-fitur spasial dari 561 variabel sensor, sementara mekanisme *Multi-Head Attention* pada *Transformer* mampu menangkap korelasi temporal dan hubungan antar-fitur yang kompleks. Hal ini dibuktikan dengan pencapaian akurasi pada data uji sebesar 93,65%.
2. Model *Hybrid* ini menunjukkan kemampuan pembelajaran yang sangat cepat (konvergen). Hanya dalam 15 epoch, model mampu mencapai akurasi *training* sebesar 96,41% dengan nilai *loss* yang sangat rendah yaitu 0,0941. Kecepatan konvergensi ini menunjukkan bahwa penggunaan mekanisme *attention* membantu model fokus pada fitur-fitur sensor yang paling relevan untuk setiap jenis aktivitas.
3. Melalui analisis *Confusion Matrix* dan *Classification Report*, penelitian ini menyimpulkan bahwa aktivitas statis dan dinamis memiliki tingkat kesulitan yang berbeda. Aktivitas Laying (berbaring) mencapai skor sempurna (1.00), sedangkan aktivitas dinamis seperti Walking (0.96) dan Walking Upstairs (0.93) memiliki reliabilitas yang tinggi. Tantangan terbesar ditemukan pada klasifikasi aktivitas Sitting dan Standing dikarenakan kemiripan pola sinyal sensor pada kondisi tubuh yang sama-sama diam, namun secara keseluruhan tetap memberikan hasil di atas ambang batas standar klasifikasi yang baik.

4. Dengan total parameter sebesar 185.862, model ini tergolong ringan (*lightweight*) namun tetap tangguh. Hal ini mengonfirmasi bahwa model *Hybrid CNN-Transformer* layak dan sangat memungkinkan untuk diimplementasikan ke dalam perangkat bergerak (*mobile device*) atau sistem *embedded* yang dibawa oleh pendaki gunung tanpa membebani daya komputasi perangkat secara berlebihan.

5.2 Saran

Meskipun hasil penelitian ini menunjukkan angka akurasi yang tinggi, masih terdapat beberapa ruang pengembangan yang dapat dilakukan untuk penelitian selanjutnya guna menyempurnakan sistem pemantauan aktivitas pendaki gunung:

1. Penelitian selanjutnya disarankan untuk menambah variasi dataset yang mencakup kondisi medan pendakian yang lebih beragam, seperti permukaan tanah yang tidak rata, berbatu, atau berlumpur. Hal ini penting untuk menguji apakah model tetap konsisten dalam mengenali pola aktivitas di bawah pengaruh gangguan lingkungan yang lebih ekstrem.
2. Mengingat arsitektur *Transformer* memiliki banyak variabel sensitif, disarankan untuk melakukan eksperimen lebih lanjut pada optimasi *hyperparameter*, seperti variasi jumlah *heads* pada *Multi-Head Attention*, penggunaan *learning rate scheduler*, serta teknik *regularization* tambahan untuk menekan celah antara akurasi *training* dan validasi agar lebih rapat.
3. Penelitian ini dapat dilanjutkan ke tahap implementasi nyata dengan mengintegrasikan model .h5 yang telah dihasilkan ke dalam aplikasi Android atau iOS yang terhubung dengan sensor pada *smartwatch* pendaki. Integrasi dengan sistem *Internet of Things* (IoT) untuk pengiriman data koordinat lokasi secara *real-time* juga akan menjadi nilai tambah yang krusial untuk aspek keselamatan (*safety*) pendakian.
4. Peneliti selanjutnya dapat membandingkan performa model ini dengan metode hybrid lain, seperti CNN-LSTM atau CNN-GRU, untuk melihat apakah struktur *Recurrent Neural Network* (RNN) mampu memberikan

pemahaman konteks temporal yang lebih baik dibandingkan mekanisme *Attention* pada durasi aktivitas yang sangat panjang.

5. Untuk mengatasi sedikit penurunan akurasi pada kelas *Sitting* dan *Standing*, penelitian berikutnya dapat menerapkan teknik *oversampling* atau *Synthetic Minority Over-sampling Technique* (SMOTE) untuk memastikan distribusi data antar-kelas benar-benar seimbang, sehingga model dapat belajar lebih adil pada aktivitas yang memiliki durasi lebih pendek.

DAFTAR PUSTAKA

- Abdullah, M. H., & Ahmed, M. A. (2024). Human Activity Recognition Using Accelerometer & Gyroscope Smartphone Sensor by Extract Statistical Features. *Journal of Robotics and Control (JRC)*, 5(5), 1390–1398. <https://doi.org/10.18196/jrc.v5i5.22443>
- Ade Ryan Pratama, Farmin Wabula, Haekal Ilmandry, Maria Laura Isabela, Mugi Raharjo, & Ronald Sianipar. (2025). Literature Review The Impact of Machine Learning in Modern Industries. *Nian Tana Sikka : Jurnal Ilmiah Mahasiswa*, 3(1), 177–182. <https://doi.org/10.59603/niantanasikka.v3i1.680>
- Akinola, D., Oyedemi, A. O., & Ajinaja, M. O. (2024). A Deep Learning-based Hybrid CNN-TRANSFORMER Model for Human Activity Recognition. *International Journal of Scientific Research in Computer Science and Engineering*, 12(6), 66–74. www.isroset.org
- Alarfaj, M., Al Madini, A., Alsafran, A., Farag, M., Chtourou, S., Afifi, A., Ahmad, A., Al Rubayyi, O., Al Harbi, A., & Al Thunaian, M. (2024). Wearable sensors based on artificial intelligence models for human activity recognition. *Frontiers in Artificial Intelligence*, 7. <https://doi.org/10.3389/frai.2024.1424190>
- Ali, S. M., Arjunan, S. P., Peter, J., Perju-Dumbrava, L., Ding, C., Eller, M., Raghav, S., Kempster, P., Motin, M. A., Radcliffe, P. J., & Kumar, D. K. (2024). Wearable Accelerometer and Gyroscope Sensors for Estimating the Severity of Essential Tremor. *IEEE Journal of Translational Engineering in Health and Medicine*, 12, 194–203. <https://doi.org/10.1109/JTEHM.2023.3329344>
- Caro-Alvaro, S., Garcia-Lopez, E., Brun-Guajardo, A., Garcia-Cabot, A., & Mavri, A. (2024). Gesture-Based Interactions: Integrating Accelerometer and Gyroscope Sensors in the Use of Mobile Apps. *Sensors*, 24(3). <https://doi.org/10.3390/s24031004>
- Contreras, C., Stanley, E. C., Deschamps-Prescott, C., Burnap, S., Hopkins, M., Browning, B., & Christensen, J. C. (2024). Evaluation of Smartphone Technology on Spatiotemporal Gait in Older and Diseased Adult Populations. *Sensors*, 24(17). <https://doi.org/10.3390/s24175839>
- Dutta, S. J., Boongoen, T., & Zwiggelaar, R. (2025). Human activity recognition: A review of deep learning-based methods. In *IET Computer Vision* (Vol. 19, Issue 1). John Wiley and Sons Inc. <https://doi.org/10.1049/cvi2.70003>

- Fahmi, Moh., Laila, R., Pusadan, M. Y., Syahrullah, S., Azhar, R., Sani, I. A., & Magfirah, M. (2025). PENERAPAN CONVOLUTION NEURAL NETWORK (CNN) UNTUK DETEKSI MEGALITIKUM DI SULAWESI TENGAH BERBASIS MOBILE. *JIPi (Jurnal Ilmiah Penelitian Dan Pembelajaran Informatika)*, 10(3), 2525–2536. <https://doi.org/10.29100/jipi.v10i3.6458>
- Hastuti, S., Ansar, A., & Hermawan, N. (2025). Penerapan Teknologi Deep Learning Dalam Pendidikan Digital . *Jurnal Penelitian Ilmu Pendidikan Indonesia*, 4, 359–365.
- Imtinan, N., & Kuswanto, H. (2023). The Use of Phyphox Application in Physics Experiments: A Literature Review. *JIPF (Jurnal Ilmu Pendidikan Fisika)*, 8(2), 183. <https://doi.org/10.26737/jipf.v8i2.4167>
- Khan, M., Anjum, S., Ibrahim, A., Nnaji, C., Aryal, A., & Koh, A. S. (2025). WEARABLE SENSOR-BASED FATIGUE CLASSIFICATION UNDER DIVERSE THERMAL CONDITIONS. *Journal of Information Technology in Construction*, 30, 875–902. <https://doi.org/10.36680/j.itcon.2025.036>
- Kurniawan, A., Marwoto, P., & Nugroho, S. E. (2025). Development and Validation of Free Fall Motion Experiment Kit Based on Arduino UNO and Phyphox Application . *Jurnal Pendidikan MIPA* , 26, 62–74.
- Nyoman, M., Sulisty, D., & Roza, F. (2025). Rancangan Simulasi Web Pada Ground Check DVOR Menggunakan Visual Studio Code. *Telekontran : Jurnal Ilmiah Telekomunikasi, Kendali Dan Elektronika Terapan*, 13(2), 288–297. <https://doi.org/10.34010/telekontran.v13i2.17515>
- Penchalaiah, M. K., Sushma, P., Anuhya, K., Nafreen, S., Amar, V., Dhanush, M., & Students, U. G. (2025). *SMART JACKET FOR HEALTH MONITORING OF CLIMBERS USING LoRaWAN TECHNOLOGY* (Vol. 12). www.jetir.org
- Portal-Porras, K., Fernandez-Gamiz, U., Zulueta, E., Irigaray, O., & Garcia-Fernandez, R. (2023). Hybrid TRANSFORMER+CNN architecture for unsteady flow prediction. *Materials Today Communications*, 35. <https://doi.org/10.1016/j.mtcomm.2023.106281>
- Sharma, A., Singh, K., & Bisht, R. (2024). Human Activity Recognition Using CNN-TRANSFORMER. *Computer Science, Engineering and Technology*, 2(3), 31–35. <https://doi.org/10.46632/cset/2/3/4>
- Simanjuntak, D. F., Djanggu, N. H., & Budiman, R. (2025). IMPLEMENTASI DALAM PERAMALAN PERMINTAAN AIR BERSIH DI KOTA PONTIANAK. *INTEGRATE: Industrial Engineering and Management System*, 9, 352–358.

- Sonawane, M., Rathod, J., & Avadhut, A. (2024). IoT Based Mountain Climber Health and Position Tracker. *International Journal of Advanced Research in Science, Communication and Technology (IJARSCT)*, 4(4).
- Sungkono, Azhar, G. A., Kusuma, A. C., & Izza, S. (2023). Differential Drive Mobile Robot Motion Accuracy Improvement with Odometry-Compass Sensor Fusion Implementation . *ELKHA : Jurnal Teknik Elektro*, 15, 24–31.
- Venter, G., & Neaves, M. (2025). SUN-DIC: A Python-based open-source software tool for Digital Image Correlation. *Advances in Engineering Software*, 211. <https://doi.org/10.1016/j.advengsoft.2025.104043>
- Völker, L. A., Abendroth, J. M., Degen, C. L., & Herb, K. (2025). *SimOS: A Python framework for simulations of optically addressable spins*. <https://doi.org/10.17632/v6vxh8pmh3.1>
- Yilmaz, A., & Kuş, İ. (2026). General CNN model for biomedical image classification via genetic algorithm-based hyperparameter optimization. *Ain Shams Engineering Journal*, 17(1), 103891. <https://doi.org/10.1016/j.asej.2025.103891>
- Yin, Y., Xie, L., Jiang, Z., Xiao, F., Cao, J., & Lu, S. (2024). A Systematic Review of Human Activity Recognition Based on Mobile Devices: Overview, Progress and Trends. *IEEE Communications Surveys and Tutorials*, 26(2), 890–929. <https://doi.org/10.1109/COMST.2024.3357591>